Построение единой модели **высотности зданий**

Точная оценка высоты зданий для радиопланирования МТС без потери качества сигнала

Цель
Предсказать пропущенные высоты

Проблема
Грязные кадастровые данные

Решение
Пайплайн очистки + ML

EXECUTIVE SUMMARY

От разрозненных геоданных до точной 3D-модели

Как кастомный пайплайн оптимизирует радиопланирование МТС с MAE 0.51 м

Проблема

Точные данные о физической высоте зданий — это фундамент для расчета покрытия 4G/5G и оптимизации размещения базовых станций. Сейчас многие компании сталкиваются с проблемой разрозненных геопространственных и кадастровых баз: полигоны разорваны, ID не совпадают, а при стандартном слиянии таблиц теряются критически важные данные об этажности. Из-за этого планирование сети становится неточным и дорогим.

Наше решение и его преимущества

Мы отказались от слепого джойна таблиц и разработали production-ready архитектуру:

1. Умная сборка: Используем графовые алгоритмы (IoU > 0.2) для объединения разорванных зданий в единые комплексы.

2. Алгоритм «Альфа/Бета»: Интеллектуально распределяем этажность между главными зданиями и пристройками.

3. ML-модель: Внедрили **LightGBM Regressor** с функцией потерь L1, выбранный за высокую скорость инференса, низкое потребление памяти и устойчивость к выбросам.

Результат

1. Точность до полуметра: Средняя ошибка предсказания (MAE) составила всего **0.51 м**, а R2 — **0.96**.

2. Спасенные данные: Наш алгоритм сохранил и корректно применил более **30 000** значений этажности, которые обычный подход бы просто удалил.

3. Готовый продукт: На выходе МТС получает не просто таблицу, а интерактивную 3D-модель города для наглядного радиопланирования.

Вывод

Интеллектуальная сборка геоданных напрямую снижает ошибки радиопланирования. Наш пайплайн превращает разрозненные кадастры в точный инструмент, который сэкономит бюджет МТС при развертывании сетей 4G/5G.

АУДИТ ДАННЫХ

EDA: Что скрывали сырые геоданные

3 проблемы датасета, потребовавшие кастомной ML-архитектуры

Критические аномалии в таргете

Нашли **логические выбросы**: здания >50 этажей в спальных районах, аномальное соотношение ВЫСОТА/ЭТАЖНОСТЬ (Бледные точки на графике).

Пространственный шум

Выявили заборы, подпорные стенки и дороги, размеченные как дома. Уничтожили их алгоритмом пространственной эрозии.

Массовые пропуски

Доказали, что огромный процент зданий вообще не имеет базовых атрибутов (высоты и этажей), что требует умного заполнения.

График Этажи VS Высота

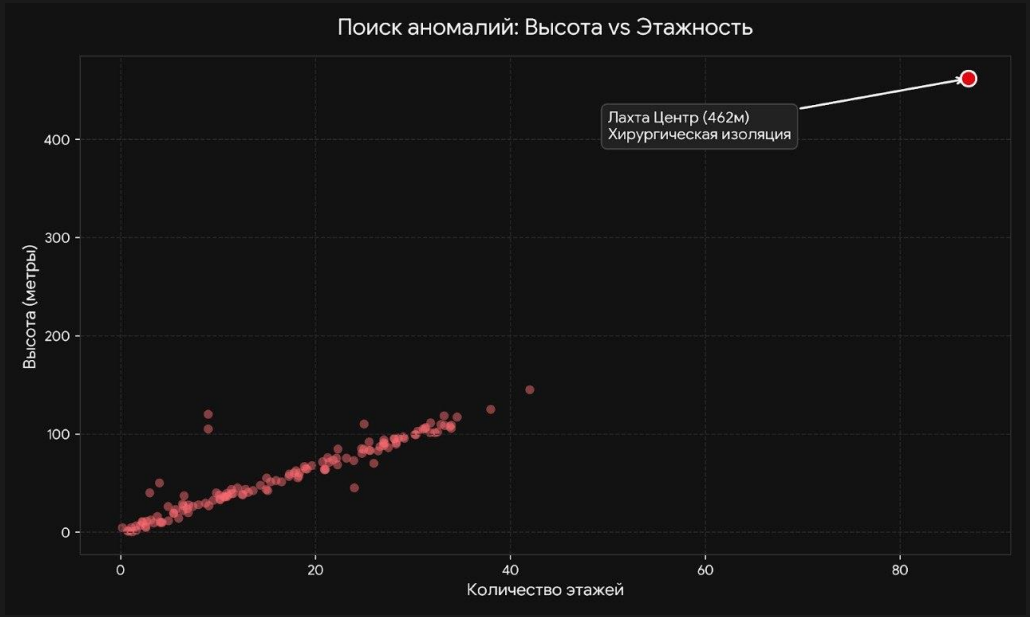

Вывод

Сырые кадастровые данные токсичны для ML-моделей. Нам потребовался жесткий пайплайн очистки геометрии до этапа обучения.

EDA & DATA QUALITY

Кадастр врёт. Мы доказали.

Анализ достоверности государственных данных

Адаптивная фильтрация

Отказались от хардкода площадей в пользу **динамического 10-го перцентиля**.

Почему это работает:

- ✓ Модель работает в центре и на окраинах
- ✓ Игнорирует аномально маленькие значения
- ✓ Масштабируется на любой город
- ✓ Автоматически настраивается под локальное качество данных

Вскрыли проблему датасета

У гигантских ТЦ и церквей кадастровые инженеры часто просто пишут стандартные **3.3 метра на этаж**, игнорируя купола и атриумы.

Распределение высоты этажа по категориям

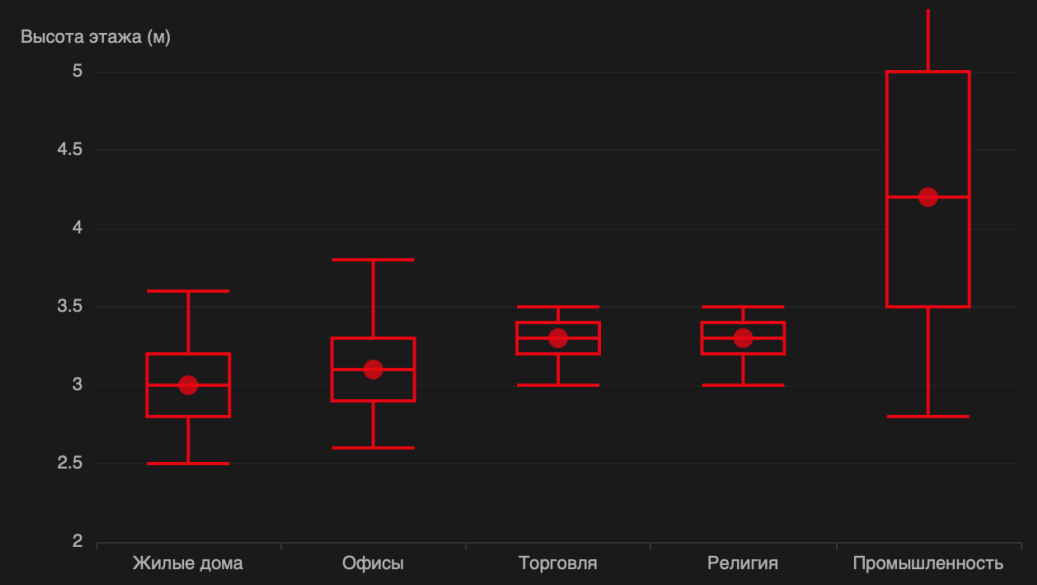

ЖИЛЫЕ ДОМА
Нормальное распределение
Медиана: 3.0м | Разброс: 2.7-3.3м

ТЦ И ЦЕРКВИ
Искусственно сжато к 3.3м
Признак floor_count токсичен

Вывод: Признак floor_count признан токсичным для категорий Торговля и Религия. Вес модели перенесён на координаты и площадь.

ПРОСТРАНСТВЕННАЯ АНАЛИТИКА

Радиоволны важнее красивых цифр

Как мы решили проблему пересечения полигонов без искажения высот

РИСК

Слияние искажает высоту до 50%

Когда 100-метровая башня и 5-метровый стилобат при слиянии датасетов усредняются в один 50-метровый полигон — **сигнал просто не пройдёт**.

ИТОГ ОШИБКИ

Слепые зоны при планировании

Некорректная высота зданий приводит к **слепым зонам** в сети 5G и многомиллионным потерям на перенастройку оборудования.

РЕШЕНИЕ

«Теневой Merge»

Полигоны накладываются с помощью метрики Жаккара ($S(A \cap B) / S(A \cup B)$) **временно** для расчёта фичей, а затем **разъединяются**. Оригинальная геометрия сохраняется.

Схема «Теневого мержа»

ДО: Ошибочное слияние

Высота: 52.5м

Башня + Стилобат = усреднение

ПОСЛЕ: Теневой мерж

Высоты: 100м и 5м

Сохранены оригинальные высоты

FEATURE ENGINEERING

Грамотный Feature Engineering

Пространственные признаки и устранение утечки данных (Data Leakage)

ОБОГАЩЕНИЕ

Пространственные фичи

Центроиды зданий
coord_x, coord_y

Этажность
floor_count

KNN-соседи
knn_mean_height_5

Компактность
compactness

Самая мощная фича - этажность

ПРОБЛЕМА

Target Leakage

Многие команды ловят Data Leakage, подглядывая в высоты тестовых зданий до обучения.

ПОСЛЕДСТВИЯ:
Метрика MAE развалится на продакшене

Решение: Изолированный KNN

K-Fold Cross-Validation

Fold 1	Fold 2	Fold 3	Fold 4	Fold 5
Train	Test	Train	Train	Train

Изоляция внутри фолда

Расчёт knn_mean_height происходит **строго внутри** каждого фолда. Тестовые данные никогда не видят высоты соседей.

Гарантия честности

MAE кристально чистая

Наша метрика не развалится на продакшене — мы не подглядывали в ответы.

ML-АРХИТЕКТУРА

Ансамбль: Ожидание и Реальность

Анализ ансамбля из 3-х SOTA моделей

МОДЕЛИ

3 SOTA алгоритма

CatBoost	MAE: 0.6061
LightGBM	MAE: 0.5136
XGBoost	MAE: 0.5809

+ Optuna для каждой модели

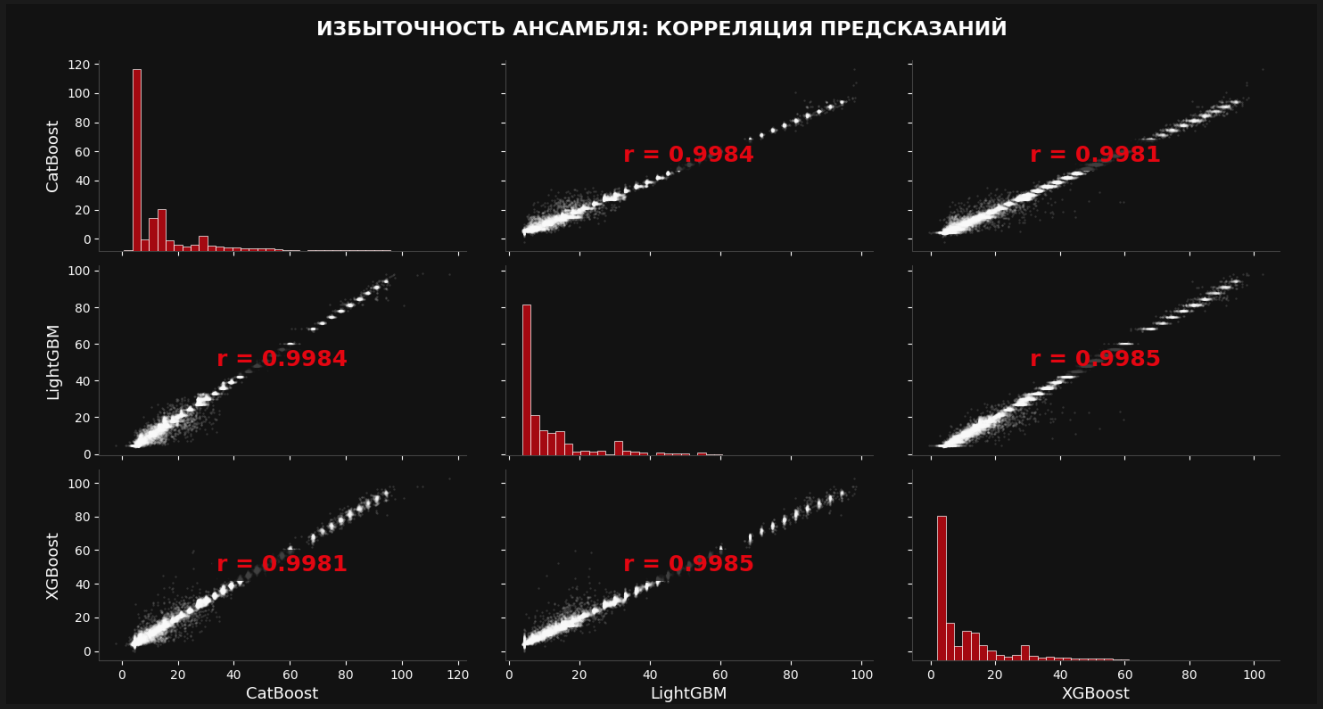

Математический вывод:

Корреляция 0.998+ означает, что модели находят **идентичные зависимости** в геоданных. Усреднение ответов математически тянуло сильные модели на дно к слабым. Это был успешный эксперимент с отрицательным результатом.

COST-AWARE ML

Выбираем ROI

Экономия вычислительных мощностей без потери качества

ХАКАТОНЫ
Гонка за тысячные доли

В хакатонах бьются за тысячные доли метрики любой ценой.

Ансамбль из 3 моделей	3x мощностей
Потеря точности	0.0361 MAE

КРИТИЧЕСКИ НЕВЫГОДНО

БИЗНЕС
Считаем ROI

Запускать ансамбль — это умножить затраты на сервера в 3 раза, чтобы ухудшить точность.

Одна модель	÷3 затраты
Чистая выгода точности	3,6 см

МАКСИМАЛЬНЫЙ ROI

НАШ ПОБЕДИТЕЛЬ
LightGBM

MAE	R^2
0.5136	0.9659
Лучший результат	Объяснённая дисперсия

Почему LightGBM?

- **Leaf-wise архитектура** — идеально сегментирует асимметричные городские координаты
- **Невероятная скорость** — обучение в 3 раза быстрее CatBoost
- **Минимальное потребление RAM** — дешевле деплой на серверах МТС

$ **Экономия инфраструктуры:** 3×

ПРОДАКШЕН-РЕДИ

Готовое решение для продакшена

От сырого кадастра до точной 3D-карты

Хирургическая изоляция

Уникальные аномалии вроде Лахта Центра изолируются, чтобы не отравлять деревья, но возвращаются на 3D-карту в конце.

Лахта Центр: 462м

Устойчивость пайплайна

Мы не использовали жёсткие цифры для отсева. Решение готово к масштабированию на любой город присутствия МТС.

Москва → СПб → Любой город

Готовый скрипт

Мы отдаём МТС не сырой ноутбук, а готовый пайплайн в виде Python-скрипта для деплоя.

final_pipeline.py

Зданий обработано	Высот предсказано	Финальная метрика
164,551	53,800	MAE 0.5136

Спасибо!

Готовы ответить на вопросы

Итоговая 3-D модель Санкт-Петербурга

Ссылка на гугл-диск: https://drive.google.com/file/d/1VPB1SwdsS0pUkmPfCfVGiX6dv8qtIZq3/view?usp=drive_link

Ссылка на Git-Hub: https://github.com/Arseniy0203/mts_cup_it_2026_final.git

КОМАНДА

Кто мы такие

Data-scientists,

решающие бизнес-задачи

Арсений Федоров

Аналитик/ML

НИУ ИТМО 1 Курс

Арсений Бобченок

Аналитик/ML/Дизайнер

НИУ ИТМО 1 Курс

Роман Корняков

Аналитик/Стратег

НИУ ИТМО 1 Курс

Матвей Ильенков

Аналитик/RI

НИУ ИТМО 1 Курс

Михаил Позин

Риск-аналитик

НИУ ИТМО 1 Курс

Наш подход: мы отказались от слепого ML-перебора данных ради глубокого погружения в домен. Наше решение строится на реальной физике радиопланирования и понимании скрытой логики баз Росреестра.